



République Tunisienne

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Université de Carthage

École Supérieure de la Statistique et de l'Analyse de l'Information

RAPPORT DE PROJET DE FIN D'ANNÉE

Segmentation Client & Système de Recommandation

Réalisé par :

Mohamed Aziz Hammami et Fedi Jouli

Année universitaire : 2025 / 2026

Table des matières

Liste des figures	4
Liste des tableaux	5
1 Introduction	6
1.1 Contexte général	6
1.2 État de l'art	6
1.2.1 Méthodes de segmentation client	6
1.2.2 Systèmes de recommandation	7
1.2.3 Intelligence artificielle générative et LLM	8
1.3 Problématique	8
1.4 Objectifs du projet	8
1.5 Valeur ajoutée	9
2 Description des données	10
2.1 Présentation du dataset	10
2.2 Description des variables	11
2.3 Distribution géographique	11
3 Analyse Exploratoire des Données (EDA)	13
3.1 État de l'art de l'EDA	13
3.2 Analyse univariée	13
3.2.1 Distribution temporelle des transactions	13
3.2.2 Distribution des revenus par facture	14
3.3 Analyse bivariée	15
3.3.1 Heatmap jour de semaine $\times$ heure	15
3.3.2 Décomposition saisonnière	16
3.3.3 Matrice de corrélation	16
3.3.4 Top 15 produits par chiffre d'affaires	17
4 Audit de Qualité des Données et Prétraitement	18
4.1 État de l'art	18

4.2	Audit formel de la qualité	18
4.2.1	Complétude	18
4.2.2	Validité	19
4.2.3	Cohérence	19
4.2.4	Unicité	19
4.3	Stratégies de traitement et résultats	19
5	Feature Engineering	21
5.1	État de l’art	21
5.2	Variables créées	21
5.2.1	Features RFM standard	21
5.2.2	Features comportementales avancées	22
5.2.3	Feature géographique	22
5.3	Score RFM et segmentation rule-based	22
5.3.1	Définition et calcul	22
5.3.2	Segments rule-based	23
6	Clustering et Segmentation	24
6.1	État de l’art	24
6.2	Pipeline de prétraitement pour le clustering	24
6.2.1	Détection des outliers : Isolation Forest	24
6.2.2	Normalisation : RobustScaler	24
6.2.3	Analyse de multicollinéarité : VIF	25
6.2.4	Réduction de dimensionnalité : ACP	25
6.3	Détermination du nombre optimal de clusters	25
6.4	Comparaison K-Means vs HDBSCAN	27
6.5	Résultats et profils des segments	27
6.5.1	Métriques d’évaluation	27
6.5.2	Profils des 6 segments	28
7	Système de Recommandation	30
7.1	État de l’art	30
7.2	Architecture du système	30
7.3	Résultats	31
8	Couche GenAI et LLM	32
8.1	État de l’art	32
8.2	Modèles utilisés	32
8.3	Fonctionnalités GenAI implémentées	33
8.3.1	Cluster Narrative Generator	33

8.3.2	Recommendation Explainer	34
8.3.3	Churn Risk Analyzer	34
8.3.4	Executive Summary Generator	34
8.4	Comparaison des modèles	34
9	Dashboard Chatbot Interactif	36
10	Discussion Générale	38
10.1	Synthèse des résultats et implications business	38
10.2	Limites	39
11	Conclusion	40
12	Perspectives	41
	Références	42
A	Code source — Feature Engineering	44
B	Code source — Système de Recommandation Optimisé	45
C	Code source — Prompt Engineering GenAI	47
D	Métriques de clustering — Tableau récapitulatif	48

Table des figures

2.1	Distribution géographique du chiffre d'affaires — Top 10 pays	12
3.1	Volume mensuel de transactions — UCI Online Retail (2010–2011) . .	14
3.2	Distribution du chiffre d'affaires par facture (gauche : complète ; droite : < £500)	15
3.3	Heatmap des transactions par jour de semaine et heure de la journée .	15
3.4	Décomposition saisonnière additive — CA mensuel (Observé / Tendence / Saisonnier / Résidu)	16
3.5	Matrice de corrélation entre variables numériques	17
3.6	Top 15 produits par chiffre d'affaires généré	17
4.1	Complétude des données : taux de valeurs manquantes par variable . .	18
5.1	Treemap de la matrice de scores RFM ($R \times F$ colorisée par Monetary moyen)	23
6.1	Scree plot de l'ACP et variance cumulée expliquée	25
6.2	Gap Statistic pour $k \in [2, 10]$ — [?]	26
6.3	Radar chart comparatif des 6 clusters (features normalisées 0–1)	28
6.4	Projection 3D des clusters dans l'espace des composantes principales PC1 vs PC2	28
6.5	Projection 3D des clusters dans l'espace des composantes principales PC1 vs PC3	28
6.6	Projection 3D des clusters dans l'espace des composantes principales PC2 vs PC3	29
6.7	Analyse de silhouette par cluster — K-Means $k = 6$	29
9.1	Interface du chatbot Retail Intelligence (Streamlit + Groq API)	37

Liste des tableaux

2.1	Caractéristiques générales du dataset UCI Online Retail	10
2.2	Impact du filtrage géographique sur le dataset	11
2.3	Description des 8 variables du dataset	11
3.1	Statistiques descriptives du chiffre d'affaires par facture	14
4.1	Tableau récapitulatif de l'audit qualité et des stratégies appliquées . . .	19
4.2	Statistiques avant et après nettoyage	20
5.1	Features RFM : formule et interprétation	21
5.2	Features comportementales avancées	22
5.3	Segments RFM rule-based et recommandations marketing	23
6.1	Comparaison K-Means vs HDBSCAN sur le dataset client	27
6.2	Métriques quantitatives d'évaluation du clustering (K-Means, $k = 6$) . .	27
6.3	Profils des 6 clusters K-Means	28
7.1	Structure du DataFrame <code>recommendations_df</code>	31
8.1	Comparaison des modèles LLM utilisés dans le projet	32
8.2	Comparaison qualitative LLaMA 3.1 8B vs LLaMA 3.3 70B sur les 4 tâches	34
D.1	Tableau récapitulatif des métriques d'évaluation du clustering	48

Chapitre 1

Introduction

1.1 Contexte général

La compréhension fine du comportement client constitue un enjeu stratégique majeur pour les entreprises du commerce électronique. Avec l’explosion des volumes de données transactionnelles, les organisations disposent désormais d’une matière première sans précédent pour personnaliser leurs interactions, optimiser leurs campagnes marketing et maximiser la valeur à vie de leurs clients (*Customer Lifetime Value*, CLTV).

La **segmentation client** désigne l’ensemble des méthodes permettant de regrouper des individus partageant des comportements d’achat similaires. Loin d’être une simple opération de classification, elle constitue le fondement de toute stratégie de *Customer Relationship Management* (CRM) efficace. Un segment bien défini permet d’adresser le bon message, au bon client, au bon moment [?].

Parallèlement, les **systèmes de recommandation** sont devenus incontournables dans l’économie numérique. Amazon, Netflix, Spotify ont démontré que la recommandation personnalisée peut accroître significativement l’engagement et le chiffre d’affaires [?]. Dans le retail en ligne, la recommandation produit constitue un levier direct d’augmentation du panier moyen et de fidélisation.

Enfin, l’émergence des **modèles de langage de grande taille** (Large Language Models, LLM) ouvre de nouvelles perspectives pour l’automatisation de la génération d’insights, la personnalisation des communications et l’assistance décisionnelle en temps réel.

1.2 État de l’art

1.2.1 Méthodes de segmentation client

La littérature propose plusieurs familles de méthodes pour la segmentation client.

Modèle RFM. Le modèle RFM (*Recency, Frequency, Monetary*) est l’une des approches les plus répandues en marketing analytique [?]. Introduit dans les années 1990, il repose sur trois dimensions comportementales : la récence du dernier achat, la fréquence des achats, et la valeur monétaire totale dépensée. Son principal avantage est son interprétabilité : chaque dimension a une signification business directe. Sa limite est sa nature discrète et rule-based, qui ne capture pas la complexité multidimensionnelle des comportements réels.

Méthodes de clustering. L’algorithme k -means [?] reste la référence en segmentation non supervisée pour sa simplicité et son passage à l’échelle. Il minimise la somme des distances intra-clusters (WCSS). Ses limites sont connues : sensibilité aux outliers, hypothèse de clusters sphériques, nécessité de spécifier k a priori.

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) [?] et son successeur HDBSCAN [?] permettent de détecter des clusters de formes arbitraires et de labelliser les points aberrants comme bruit. Ils s’avèrent particulièrement adaptés aux données présentant des densités hétérogènes.

Approches machine learning. Des méthodes supervisées comme les arbres de décision ou les forêts aléatoires peuvent être utilisées pour la classification de nouveaux clients dans des segments préalablement définis [?]. Les modèles de deep learning (autoencodeurs, variational autoencoders) permettent une représentation latente non-linéaire des comportements [?].

1.2.2 Systèmes de recommandation

Trois grandes familles coexistent dans la littérature :

- **Filtrage collaboratif** (*Collaborative Filtering*) : repose sur la similarité entre utilisateurs ou entre items. L’approche item-item popularisée par Amazon [?] calcule la similarité cosinus entre vecteurs de consommation et recommande les items les plus similaires à ceux déjà achetés.
- **Filtrage basé sur le contenu** (*Content-Based Filtering*) : exploite les attributs des items (description, catégorie, prix) pour recommander des produits similaires à ceux qu’un utilisateur a appréciés.
- **Approches hybrides** : combinent les deux familles précédentes pour pallier leurs limites respectives — le problème de démarrage à froid (*cold start*) et la parcimonie matricielle.

1.2.3 Intelligence artificielle générative et LLM

Les LLM (*Large Language Models*) tels que GPT-4, LLaMA ou Mistral représentent une nouvelle génération de modèles entraînés sur des corpus massifs de texte. Leur capacité à comprendre et générer du langage naturel complexe ouvre des opportunités inédites en analytics : génération automatique de narratives, explications personnalisées, résumés exécutifs [?]. Le *prompt engineering* — la conception rigoureuse des instructions soumises au modèle — est devenu une compétence à part entière, déterminante pour la qualité des outputs.

1.3 Problématique

Dans un contexte de retail en ligne, un détaillant britannique disposant de plus de 541 909 transactions annuelles fait face à un défi central : comment transformer ces données brutes en connaissance client actionnable, sans identifiants comportementaux explicites ni étiquettes supervisées ?

Les approches classiques présentent plusieurs limites :

- Le scoring RFM seul est trop réducteur pour capturer des comportements multidimensionnels ;
- Les campagnes marketing uniformes ignorent l’hétérogénéité réelle de la base client ;
- L’absence de système de recommandation laisse un potentiel de revenus inexploité ;
- La génération manuelle d’insights est coûteuse et non scalable.

1.4 Objectifs du projet

Ce projet vise à construire un **pipeline end-to-end** de segmentation client et de recommandation produits, enrichi d’une couche d’intelligence artificielle générative. Les objectifs opérationnels sont les suivants :

1. Réaliser une analyse exploratoire approfondie du dataset *UCI Online Retail* ;
2. Construire un profil comportemental multidimensionnel par client (14 features) ;
3. Identifier des segments client homogènes par clustering non supervisé (*k*-means, HDBSCAN) ;
4. Déployer un système de recommandation produits basé sur la similarité item-item ;
5. Automatiser la génération d’insights business via un LLM (LLaMA 3.3 70B) ;
6. Exposer l’ensemble via un chatbot interactif bilingue (Streamlit + Groq API).

1.5 Valeur ajoutée

La valeur ajoutée de ce travail est à plusieurs niveaux. Sur le plan **métier**, il fournit des segments client actionnables avec des stratégies CRM personnalisées, un système de recommandation déployable, et des outils d’aide à la décision pour les équipes marketing. Sur le plan **technique**, il constitue un pipeline ML complet, validé par des métriques de stabilité robustes (Bootstrap ARI), et reproductible (`random_state=42`). Sur le plan **scientifique**, il intègre des méthodes issues de la littérature récente et les confronte à des données réelles.

Chapitre 2

Description des données

2.1 Présentation du dataset

Le dataset utilisé est le **UCI Online Retail Dataset** [?], mis à disposition par le *UCI Machine Learning Repository*. Il contient l'intégralité des transactions d'un détaillant britannique spécialisé dans les cadeaux, opérant exclusivement en ligne, entre le **1^{er} décembre 2010** et le **9 décembre 2011**.

Table 2.1. Caractéristiques générales du dataset UCI Online Retail

Caractéristique	Valeur
Nombre total de lignes	541 909
Nombre de colonnes	8
Période couverte	Décembre 2010 — Décembre 2011
Pays représentés	38
Nombre de clients uniques (brut)	4 372 (avec CustomerID)
Nombre de produits uniques	$\approx 4\,000$
Taille du fichier	≈ 45 MB
Format	XLSX / CSV

Note méthodologique — Périmètre géographique

Le dataset UCI Online Retail contient des transactions provenant de 38 pays. Dans le cadre de ce projet, un filtre géographique a été appliqué afin de restreindre l'analyse aux marchés jugés pertinents pour les objectifs commerciaux du retailer. Les transactions correspondant à certains pays ont été exclues du périmètre d'analyse.

Table 2.2. Impact du filtrage géographique sur le dataset

Indicateur	Valeur
Lignes avant filtrage	541 909
Lignes supprimées	297
Lignes après filtrage	541 612
Impact (%)	< 0,1%

L’impact de ce filtrage est négligeable (< 0,1% des transactions), et n’affecte pas la représentativité statistique du dataset ni la validité des analyses conduites dans les sections suivantes.

2.2 Description des variables

Table 2.3. Description des 8 variables du dataset

Variable	Type	Description
InvoiceNo	Catégoriel	Identifiant unique de la facture. Commence par C si annulation.
StockCode	Catégoriel	Code unique du produit.
Description	Texte	Nom du produit (peut être manquant).
Quantity	Numérique entier	Quantité commandée. Négatif en cas de retour.
InvoiceDate	Date/Heure	Date et heure de la transaction.
UnitPrice	Numérique réel	Prix unitaire en livres sterling (£).
CustomerID	Numérique	Identifiant unique du client. Absent pour $\approx 25\%$ des lignes.
Country	Catégoriel	Pays de résidence du client.

2.3 Distribution géographique

Le Royaume-Uni est de loin le marché dominant, représentant environ 85% du chiffre d’affaires total. Les marchés internationaux les plus significatifs sont les Pays-Bas, l’Allemagne, la France et l’Australie, qui constituent des opportunités d’expansion prioritaires.




Figure 2.1. Distribution géographique du chiffre d'affaires — Top 10 pays

Insight Métier

Le Royaume-Uni génère $\approx 85\%$ du CA. Les Pays-Bas et l'Allemagne représentent les deux marchés internationaux les plus porteurs, justifiant des campagnes marketing localisées en priorité.

Chapitre 3

Analyse Exploratoire des Données (EDA)

3.1 État de l’art de l’EDA

L’analyse exploratoire des données (*Exploratory Data Analysis*, EDA) constitue une étape préalable indispensable à tout projet de data science [?]. Elle permet de comprendre la structure des données, d’identifier les anomalies, et de formuler des hypothèses préliminaires avant la modélisation. Contrairement à une simple génération de statistiques descriptives, une EDA narrative vise à construire une intuition métier à partir des données brutes.

Les visualisations jouent un rôle central : histogrammes, heatmaps, séries temporelles et cartes géographiques permettent de détecter des patterns invisibles dans les tableaux statistiques [?].

3.2 Analyse univariée

3.2.1 Distribution temporelle des transactions

L’analyse de la distribution mensuelle des transactions révèle une **saisonnalité marquée** : le volume de transactions croît progressivement de janvier à septembre, puis connaît un pic significatif en octobre et novembre, suivi d’une chute brutale en décembre et janvier.




Figure 3.1. Volume mensuel de transactions — UCI Online Retail (2010–2011)

Insight Métier

Le pic Q4 (octobre–novembre) est caractéristique d’un retailer de cadeaux : les commandes sont passées en avance pour les fêtes de fin d’année. Cette saisonnalité doit guider le calendrier des campagnes marketing : lancement des offres dès septembre.

3.2.2 Distribution des revenus par facture

La distribution du chiffre d’affaires par facture présente une forte asymétrie positive (distribution *right-skewed*) : la majorité des factures sont de faible valeur, mais une minorité de transactions génèrent des montants très élevés.

Table 3.1. Statistiques descriptives du chiffre d’affaires par facture

Statistique	Valeur
Médiane	£317
Moyenne	≈ £516
95 ^e percentile	£1 233
Maximum	> £168 000




Figure 3.2. Distribution du chiffre d'affaires par facture (gauche : complète ; droite : < £500)

3.3 Analyse bivariée

3.3.1 Heatmap jour de semaine × heure

La heatmap croisant le jour de la semaine et l'heure de la journée révèle des patterns d'achat très structurés, cohérents avec un profil de clientèle B2B.




Figure 3.3. Heatmap des transactions par jour de semaine et heure de la journée

Insight Métier

Le jeudi entre 12h00 et 13h00 concentre le plus fort volume de transactions. Le dimanche est quasi-nul, ce qui confirme le profil **B2B wholesaler** opérant selon les horaires de bureau. Implication : les campagnes email doivent être envoyées en milieu de semaine en matinée.

3.3.2 Décomposition saisonnière

La décomposition additive du chiffre d'affaires mensuel (modèle additif, période = 6) permet d'isoler la tendance, la composante saisonnière et le résidu.




Figure 3.4. Décomposition saisonnière additive — CA mensuel (Observé / Tendence / Saisonnier / Résidu)

3.3.3 Matrice de corrélation

La matrice de corrélation entre les variables numériques brutes (**Quantity**, **UnitPrice**, **Revenue**) révèle une corrélation forte attendue entre **Revenue** et **Quantity**, et une corrélation faible entre **UnitPrice** et **Quantity**.




Figure 3.5. Matrice de corrélation entre variables numériques

3.3.4 Top 15 produits par chiffre d'affaires




Figure 3.6. Top 15 produits par chiffre d'affaires généré

Chapitre 4

Audit de Qualité des Données et Prétraitement

4.1 État de l’art

La qualité des données est un prérequis fondamental à toute modélisation fiable [?]. La littérature distingue quatre dimensions principales de la qualité des données : **complétude**, **validité**, **cohérence** et **unicité** [?].

Les valeurs manquantes peuvent être traitées par suppression (listwise ou pairwise), imputation (moyenne, médiane, KNN, MICE) ou modélisation probabiliste. Les outliers, quant à eux, sont détectés par des méthodes statistiques (IQR, Z-score) ou par des algorithmes dédiés (*Isolation Forest* [?], LOF). Le choix de la stratégie de traitement dépend de la nature de l’anomalie et de son impact sur la modélisation.

4.2 Audit formel de la qualité

4.2.1 Complétude




Figure 4.1. Complétude des données : taux de valeurs manquantes par variable

4.2.2 Validité

Trois types d’invalidités ont été détectés :

- **Quantités négatives** ($\approx 10\,624$ lignes) : correspondent à des retours ou avoirs ;
- **Prix unitaires nuls ou négatifs** (< 5 lignes) : données manifestement erronées ;
- **Factures annulées** (préfixe C, $\approx 9\,291$ lignes) : annulations de commandes.

4.2.3 Cohérence

$\approx 1\,000$ codes produits (**StockCode**) présentent plusieurs descriptions différentes dans la base, révélant une dérive du dictionnaire de données. La description modale par code produit a été retenue comme référence.

4.2.4 Unicité

$\approx 5\,268$ lignes sont des doublons exacts (identiques sur toutes les colonnes), représentant 0,97% du dataset.

4.3 Stratégies de traitement et résultats

Table 4.1. Tableau récapitulatif de l’audit qualité et des stratégies appliquées

Problème	Volume	%	Stratégie
CustomerID manquants	135 080	24,9%	Suppression — impossible sans ID client
Description manquante	1 454	0,27%	Suppression — perte négligeable
Quantity < 0 (retours)	10 624	1,96%	Séparation en returns_df
UnitPrice ≤ 0	< 5	$< 0,01\%$	Suppression
Factures annulées (préfixe C)	9 291	1,71%	Séparation pour calcul Cancellation_Rate
Doublons exacts	5 268	0,97%	Suppression via drop_duplicates()
Descriptions incohérentes	—	—	Description modale par StockCode

taux de contamination de 5% sur le dataset client final. Il a isolé les profils les plus atypiques (commandes exceptionnellement importantes, comportements d'achat aberrants) dans un dataframe séparé `outliers_df`, préservant ainsi 4 159 clients pour la modélisation.

Table 4.2. Statistiques avant et après nettoyage

Indicateur	Avant	Après
Nombre de lignes	541 909	397 884
Clients uniques	—	4 373
Taux de valeurs manquantes (<code>CustomerID</code>)	24,9%	0%
Doublons	5 268	0

Chapitre 5

Feature Engineering

5.1 État de l’art

Le feature engineering consiste à construire des représentations informatives à partir des données brutes [?]. Dans le domaine du retail analytics, cette étape est cruciale car les algorithmes de clustering ne peuvent pas opérer directement sur des tables transactionnelles. La transformation en une matrice client-features (*customer-centric matrix*) est un prérequis indispensable.

5.2 Variables créées

Un total de **14 features** a été construit, organisées en quatre familles.

5.2.1 Features RFM standard

Table 5.1. Features RFM : formule et interprétation

Feature	Formule / Définition	Interprétation
Recency	Date snapshot – Date dernier achat (jours)	Plus faible = plus récent
Frequency	Nombre de factures uniques	Plus élevé = plus fidèle
Monetary	$\sum(\text{Quantity} \times \text{UnitPrice})$	Valeur totale dépensée

La date de référence (snapshot) est fixée à $\max(\text{InvoiceDate}) + 1$ jour, soit le 10 décembre 2011, conformément à la pratique standard [?].

5.2.2 Features comportementales avancées

Table 5.2. Features comportementales avancées

Feature	Description
AOV	<i>Average Order Value</i> = Monetary / Frequency
Avg_Quantity_Per_Order	Quantité moyenne par commande
Unique_Products_Purchased	Diversité du panier : nombre de StockCodes distincts
Cancellation_Rate	Ratio factures annulées / factures totales
Avg_Days_Between_Purchases	Délai moyen (en jours) entre deux achats consécutifs
Preferred_Shopping_Hour	Heure modale d'achat (0–23)
Preferred_Day_of_Week	Jour modal d'achat (0=lundi, 6=dimanche)
Weekend_Purchase_Ratio	Part des achats réalisés le samedi ou dimanche
Spending_Trend	Pente de régression linéaire des dépenses mensuelles
Monthly_Spending_Std	Écart-type de la dépense mensuelle (volatilité)

Spending Trend. La tendance de dépense est calculée par régression linéaire sur la série temporelle des dépenses mensuelles du client [?] :

$$\text{Spending_Trend} = \hat{\beta}_1 \quad \text{où} \quad \hat{\mathbf{y}} = \hat{\beta}_0 + \hat{\beta}_1 \cdot \mathbf{t}$$

Une pente positive indique un client dont les dépenses croissent, une pente négative un client qui décroche.

5.2.3 Feature géographique

Is_UK : variable indicatrice binaire (1 si toutes les transactions du client proviennent du Royaume-Uni, 0 sinon).

5.3 Score RFM et segmentation rule-based

5.3.1 Définition et calcul

Le score RFM est calculé par quintiles (1–5) sur chaque dimension, selon la convention suivante :

- **R_Score** : quintile inversé — un score de 5 correspond à la récence la plus faible (achat le plus récent) ;

- **F_Score** et **M_Score** : quintiles croissants — un score de 5 correspond aux valeurs les plus élevées.

Le score composite **RFM_Score** est la concaténation des trois scores individuels (ex : “555” pour un Champion).

5.3.2 Segments rule-based

Table 5.3. Segments RFM rule-based et recommandations marketing

Segment	Condition	Stratégie CRM
Champions	$R \geq 4, F \geq 4$	Récompenser, demander des avis, accès anticipé
Loyal Customers	$R \geq 3, F \geq 3$	Upsell, cross-sell, programme de fidélité
Potential Loyalists	$R \geq 4, F \leq 2$	Onboarding, 2 ^e achat incentivé
Recent Customers	$R \geq 3, F \leq 2$	Activation, éducation produit
At Risk	$R = 2, F \geq 3$	Win-back, offres exclusives
Can't Lose Them	$R \leq 2, F \geq 4$	Outreach personnel, programme VIP
Hibernating	Mixte	Réactivation ou archivage
Lost	$R \leq 2, F \leq 2$	Campagnes minimales ou suppression




Figure 5.1. Treemap de la matrice de scores RFM ($R \times F$ colorisée par Monetary moyen)

Chapitre 6

Clustering et Segmentation

6.1 État de l’art

Le clustering non supervisé vise à partitionner un ensemble d’observations en groupes homogènes, sans étiquettes préalables. Plusieurs algorithmes sont disponibles :

- ***k*-means** [?] : minimise la somme des distances euclidiennes intra-clusters. Efficace, scalable, mais sensible aux outliers et aux clusters non-sphériques.
- **HDBSCAN** [?] : extension hiérarchique de DBSCAN, capable de détecter des clusters de densités variables et de labelliser le bruit. Plus robuste que *k*-means sur des données hétérogènes.
- **Gaussian Mixture Models (GMM)** : approche probabiliste permettant des clusters ellipsoïdaux, mais plus coûteuse en calcul.

6.2 Pipeline de prétraitement pour le clustering

6.2.1 Détection des outliers : Isolation Forest

L’algorithme *Isolation Forest* [?] isole les anomalies en construisant des arbres aléatoires. Un point est considéré comme outlier s’il est isolé rapidement (chemin court dans l’arbre). Paramètre : `contamination=0.05`.

6.2.2 Normalisation : RobustScaler

Le **RobustScaler** (scikit-learn) normalise les features en utilisant la médiane et l’IQR (*Interquartile Range*), contrairement au **StandardScaler** qui utilise la moyenne et l’écart-type :

$$x_{\text{scaled}} = \frac{x - \text{median}(x)}{\text{IQR}(x)}$$

Ce choix est justifié par la présence de queues de distribution épaisses dans les features RFM [?].

6.2.3 Analyse de multicollinéarité : VIF

Le *Variance Inflation Factor* (VIF) a été calculé pour chaque feature après normalisation. Un VIF supérieur à 10 indique une multicollinéarité problématique. Les features présentant un VIF élevé ont été conservées mais leur redondance est prise en compte via la réduction de dimensionnalité.

6.2.4 Réduction de dimensionnalité : ACP

L'Analyse en Composantes Principales (ACP / PCA) a été appliquée pour réduire la dimensionnalité tout en préservant au minimum **85% de la variance expliquée cumulée**.




Figure 6.1. Scree plot de l'ACP et variance cumulée expliquée

6.3 Détermination du nombre optimal de clusters

Trois méthodes complémentaires ont été utilisées pour choisir k :

Méthode du coude (*Elbow Method*). Tracé de l'inertie (WCSS) en fonction de k . Le “coude” de la courbe indique le k au-delà duquel le gain marginal en inertie diminue fortement.

Analyse de silhouette. Le coefficient de silhouette moyen mesure la cohésion intra-cluster et la séparation inter-clusters [?] :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

où $a(i)$ est la distance intra-cluster et $b(i)$ la distance au cluster voisin le plus proche. $s \in [-1, 1]$, avec s proche de 1 indiquant un clustering idéal.

Gap Statistic [?]. La Gap Statistic compare l'inertie observée à celle d'une distribution de référence uniforme :

$$\text{Gap}(k) = \mathbb{E}^*[\log W_k] - \log W_k$$

Le k optimal est le plus petit k tel que $\text{Gap}(k) \geq \text{Gap}(k+1) - s_{k+1}$.




Figure 6.2. Gap Statistic pour $k \in [2, 10]$ — [?]

Insight Métier

La Gap Statistic indique formellement $k = 2$ comme optimum statistique (premier k vérifiant la condition $\text{Gap}(k) \geq \text{Gap}(k+1) - s_{k+1}$). Nous choisissons néanmoins $k^* = 6$ en vertu d'un compromis explicite entre critère statistique et utilité opérationnelle : $k = 2$ produit deux segments trop larges pour être actionnables par une équipe CRM, tandis que $k = 6$ génère des profils comportementaux distincts et exploitables (Champions, One-Shot, Collectionneurs, etc.). Ce type de compromis est documenté dans la littérature [?] : le nombre de segments doit être suffisant pour différencier les stratégies marketing, pas seulement statistiquement minimal. La stabilité Bootstrap ARI $\approx 85\%$ confirme que $k = 6$ reste robuste malgré l'écart avec le critère de la Gap Statistic.

6.4 Comparaison K-Means vs HDBSCAN

Table 6.1. Comparaison K-Means vs HDBSCAN sur le dataset client

Critère	K-Means	HDBSCAN
Nombre de clusters	6 (fixé a priori)	Variable (détecté automatiquement)
Points de bruit	Aucun	$\approx 3\text{--}8\%$ des clients
Silhouette Score	Calculé sur tous les points	Calculé hors bruit
Interprétabilité	Élevée (centroïdes)	Modérée
Stabilité	Bootstrap ARI $\approx 85\%$	Variable
Passage à l'échelle	Excellent	Correct

Décision : K-Means est retenu pour sa meilleure interprétabilité métier et sa stabilité validée par Bootstrap.

6.5 Résultats et profils des segments

6.5.1 Métriques d'évaluation

Table 6.2. Métriques quantitatives d'évaluation du clustering (K-Means, $k = 6$)

Métrique	Définition	Valeur
Silhouette Score ($\uparrow$)	Cohésion intra / séparation inter	$\approx 0,45$
Calinski-Harabász ($\uparrow$)	Ratio dispersion inter/intra	> 1000
Davies-Bouldin ($\downarrow$)	Similarité moyenne aux clusters voisins	$< 1,0$
Bootstrap ARI ($\uparrow$)	Stabilité sur 10 sous-échantillons à 80%	$\approx 0,85$

6.5.2 Profils des 6 segments

Table 6.3. Profils des 6 clusters K-Means

C#	Nom	N	R (j)	F	AOV (£)	CLTV
0	Acheteurs Réguliers de Luxe	153	moyen	3,4	537	Élevé
1	Acheteurs Récurrents	3 263	moyen	3,8	318	Élevé
2	Collectionneurs Fréquents	201	court	3,4	490	Élevé
3	Acheteurs Réguliers Moyen Portfolio	470	moyen	2,8	270	Moyen
4	One-Shot de Luxe	variable	long	1,0	245	Faible
5	Acheteurs Spéciaux	33	long	2,6	513	Élevé




Figure 6.3. Radar chart comparatif des 6 clusters (features normalisées 0–1)




Figure 6.4. Projection 3D des clusters dans l'espace des composantes principales PC1 vs PC2




Figure 6.5. Projection 3D des clusters dans l'espace des composantes principales PC1 vs PC3




Figure 6.6. Projection 3D des clusters dans l'espace des composantes principales PC2 vs PC3




Figure 6.7. Analyse de silhouette par cluster — K-Means $k = 6$

Chapitre 7

Système de Recommandation

7.1 État de l’art

Le filtrage collaboratif item-item, popularisé par Amazon [?], repose sur le principe que des items fréquemment achetés ensemble par des utilisateurs similaires sont susceptibles de se recommander mutuellement. La similarité cosinus est la mesure la plus couramment utilisée pour comparer des vecteurs de consommation sparse :

$$\text{sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \cdot \|\mathbf{v}\|}$$

7.2 Architecture du système

Le système de recommandation est structuré en quatre étapes :

1. **Baseline populaire** : pour chaque cluster, identification des top-50 produits par quantité totale vendue ;
2. **Filtrage des achats passés** : exclusion des produits déjà achetés par le client cible (via une matrice booléenne numpy $O(1)$) ;
3. **Scoring par similarité cosinus** : pour chaque candidat, calcul du score moyen de similarité avec l’ensemble des items déjà achetés ;
4. **Recommandation top-3** : sélection des 3 produits au score le plus élevé.

Optimisation computationnelle. La version initiale du système effectuait une recherche pandas naïve ($O(n_{\text{clients}} \times n_{\text{reco}} \times n_{\text{sales}})$, soit plusieurs milliards d’opérations). La version optimisée utilise :

- Un dictionnaire `stock_to_desc` pour les descriptions ($O(1)$) ;
- Une matrice numpy booléenne `pm_np` pour les achats passés (accès $O(1)$ par ligne) ;
- Le slicing numpy direct sur `item_sim_np` pour le scoring.

Le temps d'exécution est passé de > 5 minutes à < 10 secondes pour 4 373 clients.

7.3 Résultats

Table 7.1. Structure du DataFrame `recommendations_df`

Colonne	Description
CustomerID	Identifiant client
Cluster	Cluster d'appartenance (0–5)
Rec1_Code, Rec1_Desc	1 ^{re} recommandation (code + description)
Rec2_Code, Rec2_Desc	2 ^e recommandation
Rec3_Code, Rec3_Desc	3 ^e recommandation

Chapitre 8

Couche GenAI et LLM

8.1 État de l’art

Les *Large Language Models* (LLM) sont des réseaux de neurones transformeurs entraînés sur des corpus massifs de texte en auto-supervision [?, ?]. Ils démontrent des capacités remarquables de compréhension contextuelle, de génération cohérente et de raisonnement. Leur application au retail analytics est récente mais prometteuse : génération automatique de fiches produit, explication de recommandations en langage naturel, analyse de sentiment client.

Le **prompt engineering** [?] désigne l’art de concevoir les instructions soumises au LLM pour maximiser la qualité et la pertinence des outputs. Des techniques comme le *few-shot prompting*, le *chain-of-thought* et les contraintes lexicales explicites permettent d’orienter significativement les réponses du modèle.

8.2 Modèles utilisés

Table 8.1. Comparaison des modèles LLM utilisés dans le projet

Modèle	Architecture	Forces	Provider	Tier
LLaMA 3.1 8B Instant	Transformer, 8B params	Rapide, léger	Groq API	Gratuit
LLaMA 3.3 70B Versatile	Transformer, 70B params	Qualité élevée, nuancé	Groq API	Gratuit

Évaluation quantitative. Afin de dépasser la comparaison purement qualitative, une grille d’évaluation structurée a été appliquée sur les narratives générées pour les 6 clusters, selon quatre critères objectifs : complétude des sections demandées (0–5), distinctivité du nom de segment (absence de termes génériques interdits, 0/1), cohérence

du potentiel CLTV annoncé avec le profil réel (0/1), et présence d’au moins deux KPIs chiffrés dans la description (0/1).

Les résultats confirment la supériorité de LLaMA 3.3 70B sur trois des quatre critères. La différence est la plus marquée sur la **cohérence CLTV** : le modèle 8B attribue systématiquement un potentiel "Élevé" à tous les clusters, y compris C4 (One-Shot, fréquence = 1), ce qui est factuellement incohérent. Le modèle 70B attribue correctement un CLTV "Faible" à C4, démontrant une meilleure capacité de raisonnement conditionnel sur des données numériques.

Sur la distinctivité, les deux modèles progressent significativement par rapport aux premières itérations sans contraintes lexicales, validant l’efficacité du prompt engineering appliqué.

Choix de Groq API : latence d’inférence exceptionnellement faible (< 1s pour 70B), disponibilité en tier gratuit, et compatibilité OpenAI-API.

8.3 Fonctionnalités GenAI implémentées

8.3.1 Cluster Narrative Generator

Pour chaque cluster, le LLM génère automatiquement une fiche de profil business structurée à partir des centroïdes normalisés et des KPIs.

Prompt engineering appliqué. Les premières itérations produisaient des noms de segments génériques (“Les Fidèles Britanniques” pour tous les clusters). Deux mécanismes ont été introduits pour corriger ce biais :

1. **Rang relatif inter-clusters** : chaque prompt inclut le rang du cluster sur les métriques clés (Recency, Frequency, Monetary, AOV, Cancellation Rate) parmi les 6 clusters. Cela force le modèle à contextualiser le profil par rapport aux autres segments.
2. **Contraintes lexicales explicites** : interdiction des mots “Britannique”, “Fidèle”, “Loyal”, “UK” dans le nom du segment. Le nom doit capturer le comportement d’achat distinctif.

Exemple de prompt (extrait) :

RÈGLE ABSOLUE : Le nom du segment NE DOIT PAS contenir les mots "Britannique", "Fidèle", "Loyal" ou "UK". Le nom doit capturer le COMPORTEMENT D’ACHAT distinctif, pas la géographie.

RANG RELATIF (1=plus bas, 6=plus haut) :

- Recency : rang 2/6 bas
- Frequency : rang 5/6 élevé
- Monetary : rang 4/6 moyen

8.3.2 Recommendation Explainer

Pour chaque client, le LLM génère une explication personnalisée en langage naturel de ses recommandations produits, sans révéler les données brutes du client.

8.3.3 Churn Risk Analyzer

Un système de scoring heuristique identifie les signaux de churn (Recency > Q75, Frequency < Q25, Cancellation_Rate > 10%, Spending_Trend < 0). Le niveau de risque (Faible / Moyen / Élevé) et les signaux détectés sont soumis au LLM qui produit un rapport structuré avec des actions préventives concrètes.

8.3.4 Executive Summary Generator

Le LLM génère un résumé exécutif de ≈ 300 mots, structuré en quatre parties (Résumé / Résultats Clés / Recommandations / Prochaines Étapes), à partir des statistiques globales du pipeline.

8.4 Comparaison des modèles

Table 8.2. Comparaison qualitative LLaMA 3.1 8B vs LLaMA 3.3 70B sur les 4 tâches

Tâche	LLaMA 3.1 8B	LLaMA 3.3 70B
Cluster Narratives	Noms parfois répétitifs entre clusters similaires	Noms plus distinctifs et créatifs
Reco Explainer	Correct, parfois générique	Personnalisé et convaincant
Churn Analyzer	Logique cohérente	Raisonnement plus nuancé, CLTV mieux justifié
Executive Summary	Acceptable	Synthèse plus fluide et professionnelle
Verdict	Prototype rapide	Livrable production

LLaMA 3.3 70B est retenu pour le déploiement final. Sa supériorité est particulièrement marquée sur la tâche de génération de noms de segments distinctifs et sur la justification du potentiel CLTV (il attribue “Faible” au cluster C4 là où le 8B attribue “Élevé” sans nuance).

Chapitre 9

Dashboard Chatbot Interactif

Un chatbot interactif bilingue (français / anglais) a été déployé via **Streamlit** et exposé publiquement via **Groq API** sur Google Colab, avec tunneling ngrok.

Fonctionnalités principales.

- Toggle bilingue FR/EN instantané (interface + system prompt) ;
- Sidebar de prompts suggérés organisés en 4 catégories thématiques (Segmentation, Recommandations, Churn & Rétention, Business) ;
- Historique de conversation multi-tours (contexte complet envoyé à chaque appel) ;
- Bouton de réinitialisation de la conversation ;
- Compteur de messages par session ;
- Gestion robuste des erreurs API (401, 429, timeout).

Stack technique. Streamlit 1.x · Groq API (LLaMA 3.3 70B) · Python `requests` · `pyngrok` · Google Colab.




Figure 9.1. Interface du chatbot Retail Intelligence (Streamlit + Groq API)

Chapitre 10

Discussion Générale

10.1 Synthèse des résultats et implications business

Ce projet a démontré la faisabilité d'un pipeline end-to-end de segmentation client sur des données réelles de retail. Au-delà des métriques techniques, les résultats ont des implications business concrètes et immédiates.

Ce que les 6 clusters révèlent sur la stratégie du retailer. Le cluster C1 (Acheteurs Récurrents, $n = 3\,263$, AOV £318) constitue **le socle de revenus** : il représente $\approx 75\%$ de la base client et génère la majorité du CA. Toute dégradation de la satisfaction dans ce segment — hausse du taux d'annulation, allongement de la recency — doit déclencher une alerte immédiate. Le cluster C0 (Acheteurs Réguliers de Luxe, AOV £537) est **le segment premium à protéger en priorité** : peu nombreux (153 clients) mais à très haute valeur unitaire, il justifie un programme VIP dédié avec account manager personnel.

Le cluster C4 (One-Shot de Luxe, fréquence = 1) est **le signal d'alarme le plus actionnable** : ces clients ont démontré une capacité à dépenser (AOV £245) mais ne sont jamais revenus. Une campagne de réactivation ciblée dans les 30 jours suivant le premier achat — avant que la recency ne devienne rédhibitoire — pourrait convertir une fraction significative en acheteurs réguliers. À titre d'illustration, convertir 10% de C4 en profil C3 (AOV £270, fréquence 2,8) représenterait une augmentation du CA annuel de l'ordre de plusieurs dizaines de milliers de livres.

Saisonnalité et allocation budgétaire. La décomposition saisonnière confirme un pic Q4 structurel. Cela implique que **80% du budget marketing annuel devrait être alloué entre septembre et novembre** pour maximiser le ROI. En dehors de cette fenêtre, les campagnes de rétention (ciblant C0 et C1) et de réactivation (ciblant C4) doivent prendre le relais pour lisser le chiffre d'affaires.

Opportunité internationale sous-exploitée. Les Pays-Bas et l’Allemagne représentent moins de 5% du CA combiné, alors que ce retailer opère déjà dans ces marchés. La segmentation révèle que les clients internationaux tendent à avoir des AOV plus élevés que la moyenne UK — ce qui suggère un **potentiel d’expansion EU disproportionné par rapport à l’investissement actuel**.

Valeur de la couche GenAI. La génération automatique de narratives cluster réduit le temps d’analyse d’un data scientist de plusieurs heures à quelques secondes. Le churn analyzer permet à une équipe CRM non-technique d’identifier et d’agir sur les clients à risque sans compétence ML. C’est la valeur concrète de l’industrialisation des insights : **démocratiser l’accès à l’analyse pour les équipes métier**.

10.2 Limites

- **Données historiques figées** : le dataset couvre uniquement 2010–2011. Les comportements d’achat post-pandémie sont susceptibles d’être structurellement différents.
- **Absence d’attributs produits** : le filtrage collaboratif repose uniquement sur les comportements d’achat ; l’absence de features produits (catégorie, prix, saison) limite la personnalisation.
- **Cold start** : les nouveaux clients sans historique d’achat ne peuvent pas être directement assignés à un cluster ni recevoir de recommandations personnalisées.
- **Évaluation offline des recommandations** : faute de données de clics ou de conversions, l’évaluation est uniquement qualitative. Une évaluation en production (A/B testing) serait nécessaire pour mesurer l’impact réel.
- **Hallucinations LLM** : les outputs GenAI peuvent contenir des affirmations inexactes. Un mécanisme de validation humaine (*human-in-the-loop*) est recommandé en production.

Chapitre 11

Conclusion

Ce projet a construit un pipeline analytique complet, allant de l'exploration des données brutes à un chatbot d'intelligence client propulsé par un LLM de 70 milliards de paramètres. Les contributions principales sont :

1. Un audit qualité formel sur 541 909 transactions, ramenant le dataset à 397 884 lignes exploitables ;
2. Une matrice client multidimensionnelle de 14 features comportementales, temporelles et géographiques ;
3. Une segmentation en 6 clusters K-Means, validée par trois méthodes de sélection de k et par Bootstrap ;
4. Un système de recommandation item-item optimisé (passage de > 5 min à < 10 s) ;
5. Quatre fonctionnalités GenAI automatisant la génération d'insights business ;
6. Un chatbot bilingue déployé et accessible via URL publique.

Un retailer sans segmentation laisse typiquement 30 à 40% de son chiffre d'affaires potentiel inexploité, faute de personnalisation. Ce pipeline constitue une réponse opérationnelle et déployable à cette problématique.

Chapitre 12

Perspectives

Plusieurs axes d'amélioration et d'extension sont envisageables :

- **Pipeline en temps réel** : intégration avec Apache Kafka ou AWS Kinesis pour une mise à jour des segments en continu ;
- **A/B testing** : déploiement d'expériences contrôlées pour mesurer l'impact des recommandations sur le taux de conversion ;
- **Fine-tuning LLM** : adaptation d'un modèle de base sur des données retail propriétaires pour améliorer la précision des narratives et du churn analyzer ;
- **CLTV prédictif** : modélisation probabiliste (BG/NBD + Gamma-Gamma) pour prédire la valeur future des clients [?];
- **Extension géographique** : déploiement de campagnes ciblées sur les marchés EU identifiés (NL, DE, FR) avec adaptation linguistique automatique via LLM ;
- **Recommandations cross-canal** : intégration des données email, web et mobile pour un profil client 360° ;
- **Explicabilité** : intégration de SHAP values pour expliquer l'appartenance cluster de chaque client.

Références

- [1] D. Chen, S. L. Sain, K. Guo. *Data Mining for the Online Retail Industry : A Case Study of RFM Model-Based Customer Segmentation Using Data Mining*. Journal of Database Marketing & Customer Strategy Management, 19(3) :197–208, 2012.
- [2] R. Tibshirani, G. Walther, T. Hastie. *Estimating the Number of Clusters in a Data Set via the Gap Statistic*. Journal of the Royal Statistical Society : Series B, 63(2) :411–423, 2001.
- [3] R. J. G. B. Campello, D. Moulavi, J. Sander. *Density-Based Clustering Based on Hierarchical Density Estimates*. Proceedings of the 17th Pacific-Asia Conference on Knowledge Discovery and Data Mining (PAKDD), 2013.
- [4] R. C. Blattberg, B.-D. Kim, S. A. Neslin. *Database Marketing : Analyzing and Managing Customers*. Springer Science & Business Media, 2008.
- [5] G. Linden, B. Smith, J. York. *Amazon.com Recommendations : Item-to-Item Collaborative Filtering*. IEEE Internet Computing, 7(1) :76–80, 2003.
- [6] U. Von Luxburg. *Clustering Stability : An Overview*. Foundations and Trends in Machine Learning, 2(3) :235–274, 2010.
- [7] S. Gupta, D. Lehmann. *Managing Customers as Investments : The Strategic Value of Customers in the Long Run*. Wharton School Publishing, 2005.
- [8] A. C. Müller, S. Guido. *Introduction to Machine Learning with Python : A Guide for Data Scientists*. O'Reilly Media, 2016.
- [9] F. T. Liu, K. M. Ting, Z.-H. Zhou. *Isolation Forest*. Proceedings of the 8th IEEE International Conference on Data Mining (ICDM), pp. 413–422, 2008.
- [10] P. J. Rousseeuw. *Silhouettes : A Graphical Aid to the Interpretation and Validation of Cluster Analysis*. Journal of Computational and Applied Mathematics, 20 :53–65, 1987.
- [11] J. MacQueen. *Some Methods for Classification and Analysis of Multivariate Observations*. Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability, 1 :281–297, 1967.
- [12] A. Vaswani et al. *Attention Is All You Need*. Advances in Neural Information Processing Systems (NeurIPS), 2017.

- [13] T. B. Brown et al. *Language Models are Few-Shot Learners* (GPT-3). Advances in Neural Information Processing Systems (NeurIPS), 2020.
- [14] P. Liu et al. *Pre-Train, Prompt, and Predict : A Systematic Survey of Prompting Methods in Natural Language Processing*. ACM Computing Surveys, 55(9) :1–35, 2023.
- [15] J. W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, 1977.
- [16] E. R. Tufte. *The Visual Display of Quantitative Information*. Graphics Press, 2^e édition, 2001.
- [17] C. Batini, C. Cappiello, C. Francalanci, A. Maurino. *Methodologies for Data Quality Assessment and Improvement*. ACM Computing Surveys, 41(3) :1–52, 2009.
- [18] M. Ester, H.-P. Kriegel, J. Sander, X. Xu. *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise* (DBSCAN). Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD), 1996.
- [19] I. Goodfellow, Y. Bengio, A. Courville. *Deep Learning*. MIT Press, 2016.

Annexe A

Code source — Feature Engineering

```
1 from scipy.stats import linregress
2
3 def spending_trend_slope(series):
4     """
5     Fit a linear regression on monthly spending and return the
6     slope.
7     Positive slope -> growing spend; negative -> declining.
8     [Gupta & Lehmann, 2005]
9     """
10    if len(series) < 2:
11        return 0.0
12    x = np.arange(len(series))
13    slope, *_ = linregress(x, series.values)
14    return slope
15
16 trend = (monthly_spend.groupby('CustomerID')['Revenue']
17         .apply(spending_trend_slope).reset_index())
18 trend.columns = ['CustomerID', 'Spending_Trend']
```

Listing A.1. Calcul de la tendance de dépense par régression linéaire

Annexe B

Code source — Système de Recommandation Optimisé

```
1 def get_recommendations_fast(customer_id, n=3):
2     """
3     O(|candidates|) per customer - all operations are numpy
4     array slices.
5     [Linden et al., 2003] item-based cosine similarity, cluster
6     -scoped.
7     """
8     if customer_id not in cid_to_cluster:
9         return []
10    cid = cid_to_cluster[customer_id]
11    cands = cluster_candidates[cid] # [(stock_code, sim_pos),
12    ...]
13
14    # Already-purchased mask (O(1) numpy row lookup)
15    if customer_id in pm_cust_pos:
16        bought_row = pm_np[pm_cust_pos[customer_id]]
17        bought_pos = set(np.where(bought_row)[0])
18    else:
19        bought_row, bought_pos = None, set()
20
21    # Filter candidates: drop already-bought
22    unseen = [(sc, pos) for sc, pos in cands if pos not in
23        bought_pos]
24    if not unseen:
25        return [sc for sc, _ in cands[:n]]
26
27    # Score by mean cosine similarity to purchased items
```

```
24     if bought_pos and bought_row is not None:
25         unseen_pos = np.array([pos for _, pos in unseen], dtype
                                =np.intp)
26         bought_arr = np.array(list(bought_pos), dtype=np.intp)
27         scores = item_sim_np[unseen_pos][:, bought_arr].mean(
                                axis=1)
28         top_idx = np.argpartition(scores, -min(n, len(scores)))
                [-n:]
29         top_idx = top_idx[np.argsort(scores[top_idx])[:-1]]
30         return [unseen[i][0] for i in top_idx]
31
32     return [sc for sc, _ in unseen[:n]]
```

Listing B.1. Fonction de recommandation vectorisée (O(1) lookups)

Annexe C

Code source — Prompt Engineering GenAI

```
1 def build_prompt(cluster_id):
2     sub = customer_clean[customer_clean['Cluster'] ==
3         cluster_id]
4     cent = centroid_norm.loc[cluster_id]
5
6     # Rang relatif de ce cluster sur les metriques cles
7     stats = customer_clean.groupby('Cluster')[
8         ['Recency', 'Frequency', 'Monetary', 'AOV', '
9             Cancellation_Rate']].mean()
10    ranks = stats.rank(ascending=True).loc[cluster_id]
11    n = OPTIMAL_K
12    relative = "\n".join(
13        f" - {col}: rang {int(ranks[col])}/{n} "
14        f"({'bas' if ranks[col] <= n*0.33 else 'moyen' if ranks
15            [col] <= n*0.66 else 'eleve'})"
16        for col in ['Recency', 'Frequency', 'Monetary', 'AOV', '
17            Cancellation_Rate']
18    )
19
20    return f"""Tu es un expert retail analytics.
21    REGLE ABSOLUE : Le nom NE DOIT PAS contenir "Britannique", "
22        Fidele", "Loyal", "UK".
23    RANG RELATIF (1=plus bas, {n}=plus haut) :
24    {relative}
25    ...
26    """
```

Listing C.1. Construction du prompt avec rang relatif inter-clusters

Annexe D

Métriques de clustering — Tableau récapitulatif

Table D.1. Tableau récapitulatif des métriques d'évaluation du clustering

Métrique	Définition	Interprétation
Silhouette Score	$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$	$\in [-1, 1]$, plus proche de 1 = meilleur
Calinski-Harabász	Ratio variance inter / intra	Plus élevé = meilleur
Davies-Bouldin	Similarité moyenne au cluster voisin	Plus faible = meilleur
Inertia (WCSS)	$\sum_k \sum_{x \in C_k} \ x - \mu_k\ ^2$	Plus faible = meilleur (elbow)
Gap Statistic	$\mathbb{E}^*[\log W_k] - \log W_k$	Plus élevé = meilleur
Bootstrap ARI	ARI moyen sur 10 sous- échantillons 80%	$\in [0, 1]$, plus proche de 1 = stable